

Adatbázisok 1.

Relációs adatbázis tervezés – 4. rész

Funkcionális függőségek

Felbontások

Normálformák

Relációs sémák tervezése

- Cél: az anomáliák és a redundancia megszüntetése.
 - *Módosítási anomália*
 - *Törlési anomália*
 - *Beszúrási anomália*

Példa: rosszul tervezett séma

Főnökök(név, cím, kedveltSörök, gyártó, kedvencSör)

név	cím	kedveltSörök	gyártó	kedvencSör
Janeway	Voyager	Bud	A.B.	WickedAle
Janeway	???	WickedAle	Pete's	???
Spock	Enterprise	Bud	???	Bud

Redundáns adat, a ??? helyén a
név -> cím kedvencSör és kedveltSörök -> gyártó FF-ek
felhasználásával tudjuk, mi szerepel.

A rosszul tervezettség anomáliákat is eredményez

név	cím	kedveltSörök	gyártó	kedvencSör
Janeway	Voyager	Bud	A.B.	WickedAle
Janeway	Voyager	WickedAle	Pete's	WickedAle
Spock	Enterprise	Bud	A.B.	Bud

- **Módosítási anomália:** ha Janeway-t *Judyra* módosítjuk, megteesszük-e ezt minden sornál?
- **Törlési anomália:** ha már senki sem szereti a Bud sört, azt sem fogjuk tudni, hogy ki gyártotta.
- **Beszúrási anomália:** ha nem lehet ismeretlen a kedveltSörökre vonatkozó érték, akkor nem tudunk felvenni egy antialkoholista főnököt

Relációk felbontása

- R relációt, $\{A_1, A_2, \dots, A_n\}$ attribútumokkal helyettesítsük $S(B_1, B_2, \dots, B_m)$ és $T(C_1, C_2, \dots, C_k)$ relációkkal úgy, hogy
 1. $\{A_1, A_2, \dots, A_n\} = \{B_1, B_2, \dots, B_m\} \cup \{C_1, C_2, \dots, C_k\}$
 2. $S = \Pi_{B_1, B_2, \dots, B_m}(R)$
 3. $T = \Pi_{C_1, C_2, \dots, C_k}(R)$

Veszteségmentes felbontás

- Ha $r = \Pi_{R_1}(r) \mid X \mid \dots \mid X \mid \Pi_{R_k}(r)$ teljesül, akkor az előbbi összekapcsolásra azt mondjuk, hogy **veszteségmentes**. Itt r egy R sémájú relációt jelöl.
- $\Pi_{R_i}(r)$ jelentése: r sorai az R_i attribútumaira projektálva.
- **Megjegyzés:** könnyen látható, hogy $r \subseteq \Pi_{R_1}(r) \mid X \mid \dots \mid X \mid \Pi_{R_k}(r)$ mindig teljesül. (Miért?)

R

A	B	C
a	b	c
d	e	f
c	b	c

R_1

A	B
a	b
d	e
c	b

R_2

B	C
b	c
e	f

Példa

- A szétvágás után keletkező relációk összekapcsolása nem veszteségmentes:

R

A	B	C
a	b	c
c	b	e

R₁

A	B
a	b
c	b

R₂

B	C
b	c
b	e

Boyce-Codd normálforma

- R reláció **BCNF** normálformában van, ha minden $X \rightarrow Y$ nemtriviális FF-re R -ben X superkulcs.
 - *Nemtriviális*: Y nem része X -nek.
 - *Szuperkulcs*: tartalmaz kulcsot (ő maga is lehet kulcs).

Példa

Főnökök(név, cím, kedveltSörök, gyártó, kedvencSör)

FF-ek: név->cím kedvencSör, kedveltSörök->gyártó

- Itt egy kulcs van: {név, kedveltSörök}.
- A baloldalak egyik FF esetén sem szuperkulcsok.
- Emiatt az *Főnökök* reláció nincs BCNF normálformában.

Még egy példa

Sörök(név, gyártó, gyártóCím)

FF-ek: név->gyártó, gyártó->gyártóCím

- Az egyetlen kulcs {név} .
- név->gyártó nem sérti a BCNF feltételét, de a gyártó->gyártóCím függőség igen.


BCNF-re való felbontás

- Adott R reláció és F funkcionális függőségek.
- Van-e olyan $X \rightarrow Y$ FF, ami sérti a BCNF-t?
 - Ha van olyan következmény FF F -ben, ami sérti a BCNF-t, akkor egy F -beli FF is sérti.
- Kiszámítjuk X^+ -t:
 - Ha itt nem szerepel az összes attribútum, X nem superkulcs.

R dekomponálása $X \rightarrow Y$ felhasználásával

- R -t helyettesítsük az alábbiakkal:
 1. $R_1 = X^+$.
 2. $R_2 = R - (X^+ - X)$.
- *Projektáljuk* a meglévő F -beli FF-eket a két új relációsémára.

Dekomponálási kép



Példa: BCNF dekompozíció

Főnökök(név, cím, kedveltSörök, gyártó, kedvencSör)

$F = \text{név} \rightarrow \text{cím}, \text{név} \rightarrow \text{kedvencSör},$
 $\text{kedveltSörök} \rightarrow \text{gyártó}$

- Vegyük $\text{név} \rightarrow \text{cím}$ FF-t:
- $\{\text{név}\}^+ = \{\text{név}, \text{cím}, \text{kedvencSör}\}.$
- A dekomponált relációsémák:
 1. Főnökök1(név, cím, kedvencSör)
 2. Főnökök2(név, kedveltSörök, gyártó)

Példa -- folytatás

- Meg kell néznünk, hogy az Főnökök1 és Főnökök2 táblák BCNF-ben vannak-e.
- Az FF-ek projektálása könnyű.
- A Főnökök1(név, cím, kedvencSör), az FF-ek név->cím és név->kedvencSör.
 - Tehát az egyetlen kulcs: {név}, azaz az Főnökök1 BCNF-ben van.

Példa -- folytatás

- Az $Főnök2(\underline{név}, \underline{kedveltSörök}, gyártó)$ esetén az egyetlen FF
 $kedveltSörök \rightarrow gyártó$, az egyetlen kulcs: $\{név, kedveltSörök\}$.
 - Sérül a BCNF.
- $kedveltSörök^+ = \{kedveltSörök, gyártó\}$, az $Főnök2$ felbontása:
 1. $Főnök3(\underline{kedveltSörök}, gyártó)$
 2. $Főnök4(\underline{név}, \underline{kedveltSörök})$

Példa -- befejezés

- Az *Főnökök* dekompozíciója tehát:
 1. *Főnök1*(név, cím, kedvencSör)
 2. *Főnök3*(kedveltSörök, gyártó)
 3. *Főnök4*(név, kedveltSörök)
- Az *Főnök1* az főnökökről, az *Főnök3* a sörökről, az *Főnök4* az főnökökről és kedvelt söreikről tartalmaz információt.

Példa – anomáliák?

név	cím	kedveltSörök	gyártó	kedvencSör
Janeway	Voyager	Bud	A.B.	WickedAle
Janeway	Voyager	WickedAle	Pete's	WickedAle
Spock	Enterprise	Bud	A.B.	Bud

1. Főnök1(név, cím, kedvencSör)
2. Főnök3(kedveltSörök, gyártó)
3. Főnök4(név, kedveltSörök)

név	cím	kedvencSör
Janeway	Voyager	WickedAle
Spock	Enterprise	Bud

kedveltSörök	gyártó
Bud	A.B.
WickedAle	Pete's

név	kedveltSörök
Janeway	Bud
Janeway	WickedAle
Spock	Bud

Miért működik a BCNF?

- (R, F) esetén ha R_1, \dots, R_k egy veszteségmentes felbontás, S_1, S_2 pedig R_1 veszteségmentes felbontása, akkor $S_1, S_2, R_2, \dots, R_k$ is veszteségmentes felbontás.
- Könnyen ellenőrizhető, hogy a BCNF felbontásos dián az R_1, R_2 veszteségmentes. Ehhez:
Feladat: bizonyítsuk be, hogy ha az $R(A, B, C)$ reláció esetén $B \rightarrow C$ teljesül, akkor az $R_1(A, B), R_2(B, C)$ felbontás mindig veszteségmentes.
- Minden két attribútumú séma BCNF normálformában van.
- A fentiekkel igazolható:
- Az algoritmus tehát valóban veszteségmentes felbontást ad, ám sajnos **exponenciális** lépésszámú is lehet a függőségek vetítése miatt.

Chase-teszt veszteségmentességhez I.

- Példa: adott $R(A, B, C, D)$, $F = \{ A \rightarrow B, B \rightarrow C, CD \rightarrow A \}$ és az $R_1(A, D)$, $R_2(A, C)$, $R_3(B, C, D)$ felbontás. Kérdés veszteségmentes-e a felbontás?
- Vegyük $R_1 \mid X \mid R_2 \mid X \mid R_3$ egy $t = (a, b, c, d)$ sorát. Bizonyítani kell, hogy t R egy sora. A következő tablót készítjük el:

A	B	C	D
a	b_1	c_1	d
a	b_2	c	d_2
a_3	b	c	d

Itt pl. az (a, b_1, c_1, d) sor azt jelzi, hogy R -nek van olyan sora, aminek R_1 -re való levetítése (a, d) , ám ennek a B és C attribútumokhoz tartozó értéke ismeretlen, így egyáltalán nem biztos, hogy a t sorról van szó.

Chase-teszt veszteségmentességhez II.

- Az F-beli függőségeket használva egyenlővé tesszük azokat a szimbólumokat, amelyeknek ugyanazoknak kell lennie, hogy valamelyik függőség ne sérüljön.
 - Ha a két egyenlővé teendő szimbólum közül az egyik index nélküli, akkor a másik is ezt az értéket kapja.
 - Két indexes szimbólum esetén a kisebbik indexű értéket kapja meg a másik.
 - A szimbólumok minden előfordulását helyettesíteni kell az új értékkel.
- Az algoritmus véget ér, ha valamelyik sor t -vel lesz egyenlő, vagy több szimbólumot már nem tudunk egyenlővé tenni.

Chase-teszt veszteségmentességhez III.

A	B	C	D
a	b ₁	c ₁	d
a	b ₂	c	d ₂
a ₃	b	c	d

$A \rightarrow B$



A	B	C	D
a	b ₁	c ₁	d
a	b ₁	c	d ₂
a ₃	b	c	d

$B \rightarrow C$



A	B	C	D
a	b ₁	c	d
a	b ₁	c	d ₂
a ₃	b	c	d

$CD \rightarrow A$




A	B	C	D
a	b ₁	c	d
a	b ₁	c	d ₂
a	b	c	d

Chase-teszt veszteségmentességhez IV.

- Ha t szerepel a tablóban, akkor valóban R -nek egy sora, és mivel t -t tetszőlegesen választottuk, ezért a felbontás veszteségmentes.
- Ha nem kapjuk meg t -t, akkor viszont a felbontás nem veszteségmentes.
- Példa: $R(A, B, C, D)$, $F = \{ B \rightarrow AD \}$, a felbontás: $R_1(A, B)$, $R_2(B, C)$, $R_3(C, D)$.

A	B	C	D
a	b	c ₁	d ₁
a ₂	b	c	d ₂
a ₃	b ₃	c	d

$B \rightarrow AD$



A	B	C	D
a	b	c ₁	d ₁
a	b	c	d ₁
a ₃	b ₃	c	d

Itt az eredmény jó ellenpélda, hiszen az összekapcsolásban szerepel $t = (a, b, c, d)$, míg az eredeti relációban nem.

Chase-teszt veszteségmentességhez V.

- $\{A, B\}, \{(a, b), (a_3, b_3)\}$.
- $\{B, C\}, \{(b, c_1), (b, c), (b_3, c)\}$,
- $\{C, D\}, (c_1, d_1), (c, d_1), (c, d)\}$
- $\bowtie, \{(a, b, c_1), (a, b, c), (a_3, b_3, c)\}$.
- $\bowtie, \{(a, b, c_1, d_1), (a, b, c, d_1), (a, b, c, d), (a_3, b_3, c, d_1), (a_3, b_3, c, d)\}$.
- 2 extra sor (rekord), és (a, b, c, d) , amit kell is tartalmaznia.