A számításelmélet alapjai I.

3. előadás

előadó: Tichler Krisztián ktichler@inf.elte.hu

Lineáris grammatikák

Definíció

Egy $G = \langle N, T, P, S \rangle$ környezetfüggetlen grammatikát **lineárisnak** nevezünk, ha minden szabálya vagy

- a) $A \rightarrow u, A \in N, u \in T^*$ vagy
- b) $A \rightarrow u_1 B u_2$ alakú, ahol $A, B \in N$ és $u_1, u_2 \in T^*$.

A G lineáris grammatikát **bal-lineárisnak** nevezzük, ha minden b) alakú szabályában $u_1 = \varepsilon$.

A G lineáris grammatikát **jobb-lineárisnak** mondjuk, ha minden b) alakú szabályában $u_2 = \varepsilon$.

Megjegyzés: A jobb-lineáris grammatika egy másik elnevezés a reguláris (3-típusú) grammatikákra.

Példa:

1. $S \rightarrow aSb \mid \varepsilon$	lineáris, de nem bal- és nem jobblineáris
2. $S \rightarrow Saa \mid b$	bal-lineáris

3. $S \rightarrow aS \mid bbS \mid c$ jobb-lineáris

Lineáris grammatikák és nyelvek

Definíció

Egy L nyelvet lineárisnak, bal-lineárisnak, illetve jobb-lineárisnak mondunk, ha van olyan G lineáris, bal-lineáris, illetve jobb-lineáris grammatika, amelyre L = L(G) teljesül.

Megjegyzés: A jobb-lineáris nyelvek tehát azonosak a reguláris (3-típusú) nyelvekkel.

Tétel

Minden bal-lineáris grammatika reguláris (3-típusú) nyelvet generál.

Bal- és jobblineáris nyelvek

Bizonyítás: Legyen $G = \langle N, T, P, S \rangle$ bal-lineáris grammatika és legyen $N = \{S, A_1, \dots, A_n\}$.

Az általánosság megszorítása nélkül feltehetjük, hogy S nem fordul elő egyetlen szabály jobboldalán sem.

Megkonstruálunk egy $G' = \langle N, T, P', S \rangle$ jobb-lineáris grammatikát, amelyre L(G) = L(G') teljesül.

- 1. $S \rightarrow u :\in P'$ akkor és csak akkor, ha $S \rightarrow u \in P$,
- 2. $S \rightarrow uA_k :\in P'$ akkor és csak akkor, ha $A_k \rightarrow u \in P$,
- 3. $A_j \rightarrow uA_k :\in P'$ akkor és csak akkor, ha $A_k \rightarrow A_j u \in P$,
- **4.** A_j → u :∈ P' akkor és csak akkor, ha S → A_ju ∈ P.

 $(u \in T^* \text{ minden a 4 pontban})$

Megmutatjuk, hogy L(G) = L(G').

Bal- és jobblineáris nyelvek

$$L(G) \subseteq L(G')$$
:
Legyen $w \in L(G)$.

$$S \to u :\in P' \qquad \leftrightarrow \qquad S \to u \in P,$$

$$S \to uA_k :\in P' \qquad \leftrightarrow \qquad A_k \to u \in P,$$

$$A_j \to uA_k :\in P' \qquad \leftrightarrow \qquad A_k \to A_j u \in P,$$

$$A_j \to u :\in P' \qquad \leftrightarrow \qquad S \to A_j u \in P.$$

- **1. eset** Ha $S \rightarrow w \in P$, akkor $S \rightarrow w \in P'$, így $w \in L(G')$.
- 2. eset Egyébként w-hez van G-ben egy

$$S \Rightarrow A_{i_1} w_1 \Rightarrow A_{i_2} w_2 w_1 \Rightarrow \cdots \Rightarrow A_{i_{m-1}} w_{m-1} \cdots w_1 \Rightarrow w_m w_{m-1} \cdots w_1 = w$$

levezetés ($m \ge 2$). Azonban ekkor G' -ben létezik egy

$$S\Rightarrow w_mA_{i_{m-1}}\Rightarrow w_mw_{m-1}A_{i_{m-2}}\Rightarrow\cdots\Rightarrow w_m\cdots w_2A_{i_1}\Rightarrow w_m\cdots w_1=w$$
 levezetés, azaz $w\in L(G')$.

$$L(G') \subseteq L(G)$$
:

Következik a szimmetriából.

Bal- és jobblineáris nyelvek

Példa:

$$L = \{a^n b^k \mid n, k \in \mathbb{N}\}.$$

$$S \rightarrow u :\in P' \qquad \leftrightarrow \qquad S \rightarrow u \in P,$$

 $S \rightarrow uA_k :\in P' \qquad \leftrightarrow \qquad A_k \rightarrow u \in P,$
 $A_j \rightarrow uA_k :\in P' \qquad \leftrightarrow \qquad A_k \rightarrow A_j u \in P,$
 $A_j \rightarrow u :\in P' \qquad \leftrightarrow \qquad S \rightarrow A_j u \in P.$

$$P$$

$$S \to \varepsilon$$

$$S \to A_1 b$$

$$S \to A_2 a$$

$$A_1 \to A_1 b$$

$$A_1 \to A_2$$

$$A_2 \to A_2 a$$

$$A_2 \to A_2 a$$

$$A_3 \to A_2 a$$

$$A_4 \to A_2 a$$

$$A_5 \to A_2 a$$

$$A_6 \to \varepsilon$$

$$S \rightarrow \varepsilon$$

$$A_{1} \rightarrow b$$

$$A_{2} \rightarrow a$$

$$A_{1} \rightarrow bA_{1}$$

$$A_{2} \rightarrow A_{1}$$

$$A_{2} \rightarrow aA_{2}$$

$$S \rightarrow A_{2}$$

$$S \Rightarrow A_1b \Rightarrow A_2b \Rightarrow A_2ab \Rightarrow ab$$
. $S \Rightarrow A_2 \Rightarrow aA_2 \Rightarrow aA_1 \Rightarrow ab$.

L₃ tükrözésre való zártsága

Állítás: Minden $G = \langle N, T, P, S \rangle$ jobb-lineáris grammatikához meg tudunk konstruálni egy G' bal-lineáris grammatikát, amely L(G) tükörképét generálja.

Bizonyítás: G'-ben vegyük a G-beli $A \to u$ és $A \to uB$ alakú szabályok helyett az $A \to u^{-1}$ illetve $A \to Bu^{-1}$ szabályokat $(A, B \in N, u \in T^*)$.

Következmény:

- 1. \mathcal{L}_3 zárt a tükrözés (megfordítás) műveletére nézve.
- 2. Minden reguláris nyelv generálható bal-lineáris grammatikával.

Bizonyítás:

- **1.** Ha $L \in \mathcal{L}_3$, akkor az állítás miatt L^{-1} generálható egy bal-lineáris G grammatikával. Az előző tétel alapján $L^{-1} \in \mathcal{L}_3$.
- **2.** Ha $L \in \mathcal{L}_3$, akkor az épp most bizonyított **1.** miatt $L^{-1} \in \mathcal{L}_3$ is igaz, így L^{-1} jobb-lineáris grammatikával generálható. Az állítás miatt $(L^{-1})^{-1} = L$ bal-lineáris grammatikával generálható.

Tétel

Minden 3-típusú, azaz reguláris nyelv generálható egy olyan grammatikával, amelynek szabályai vagy

- \rightarrow X \rightarrow aY, X, Y \in N, a \in T vagy
- ▶ $X \rightarrow \varepsilon$ alakúak, ahol $X \in N$.

Bizonyítás: Legyen $G = \langle N, T, P, S \rangle$ 3-típusú grammatika. Ismeretes, hogy G szabályai vagy

- a) $A \rightarrow uB$ vagy
- b) $A \rightarrow u$ alakúak $(A, B \in N, u \in T^*)$.

A G grammatikát a megfelelő alakra transzformáljuk, figyelve arra hogy az eredmény G-vel ekvivalens legyen.

A transzformáció lépései:

- 1. lépés: Hosszredukció
- 2. lépés: Láncmentesítés

1. lépés: Hosszredukció

a) típusú szabályok:

Ha $A oup uB \in P$ $(A, B \in N, u \in T^*)$, |u| > 1 és $u = a_1 \cdots a_n$, $n \ge 2$, akkor helyettesítsük az $A oup a_1 \cdots a_n B$ szabályt az $\{A oup a_1 Z_1, Z_1 oup a_2 Z_2, \dots Z_{n-1} oup a_n B\}$ szabályhalmazzal, ahol Z_1, \dots, Z_{n-1} új, a szabályhoz bevezetett egyedi nemterminálisok.

b) típusú szabályok:

Hasonlóan, Ha $A \rightarrow u \in P$ ($A \in N, u \in T^*$), |u| > 0 és $u = a_1 \cdots a_m, m \geq 1$, akkor helyettesítsük az $A \rightarrow a_1 \cdots a_m$ szabályt az $\{A \rightarrow a_1 Y_1, Y_1 \rightarrow a_2 Y_2, \dots Y_{m-1} \rightarrow a_m E, E \rightarrow \varepsilon\}$ szabályhalmazzal, ahol Y_1, \dots, Y_{m-1} új, a szabályhoz bevezetett egyedi nemterminálisok. E szintén új nemterminális, de elég a b) típusú szabályok hosszredukciójához egy közös új ε szabály.

Az eddigi szavakat az átalakítás után is generálni lehet. Mivel az új nemterminálisok szabályonként egyediek, így nem lehetséges az eddigieken felül további szó generálása.

2. lépés: Láncmentesítés

A hosszredukció után kapott P_1 szabályhalmaz elemei $X \to aY, X \to Y, X \to \varepsilon$ alakúak, ahol $X, Y \in N$ és $a \in T$. Már csak az $X \to Y$ alakú, ú.n. láncszabályokat kell eliminálni. Jelölje P_0 a P_1 -beli láncszabályok halmazát.

Első lépésben meghatározzuk minden $A \in N$ esetén a $H(A) := \{B \in N \mid A \Rightarrow^* B\}$ halmazokat.

H(A) hatékony előállításához definiáljuk rekurzívan a $H_i(A)$ ($i \ge 0$) halmazokat az alábbiak szerint:

$$H_0(A) := \{A\}$$
 $H_{i+1}(A) := H_i(A) \cup \{B \in N \mid \exists C \in H_i(A) \text{ amelyre } C \rightarrow B \in P\}.$
 $H_0(A) \subseteq H_1(A) \subseteq \cdots \subseteq H_k(A) \subseteq \cdots \subseteq N$
 $k := \min\{0 \le i \le n-1 \mid H_i(A) = H_{i+1}(A)\}.$
 $H(A) := H_k(A).$

 $P' := \{A \rightarrow w \mid \exists B \in H(A), \text{ amelyre } B \rightarrow w \in P\} \setminus P_0.$

Példa:

1. lépés: Hosszredukció

 $S \rightarrow abS$

 $S \rightarrow aZ_1 \qquad Z_1 \rightarrow bS$

 $S \rightarrow B$

 $S \rightarrow B$

 $B \rightarrow bB$

 $B \rightarrow bB$

 $B \rightarrow V$

 $B \rightarrow V$

 $V \rightarrow aa$

 $V \rightarrow aZ_2 \qquad Z_2 \rightarrow aE$

 $V \rightarrow b$

 $V \rightarrow bE$ $E \rightarrow \varepsilon$

2. lépés: Láncmentesítés $S \rightarrow aZ_1$ $Z_1 \rightarrow bS$

 $S \rightarrow aZ_1 \qquad Z_1 \rightarrow bS$

S o bB

 $S \rightarrow B$

 $S \rightarrow aZ_2$ $S \rightarrow bE$

 $B \rightarrow bB$

 $B \rightarrow bB$

 $B \rightarrow V$

 $B \rightarrow aZ_2$ $B \rightarrow bE$

 $V \rightarrow aZ_2$ $Z_2 \rightarrow aE$ $V \rightarrow aZ_2$ $Z_2 \rightarrow aE$

 $V \rightarrow bE$ $E \rightarrow \varepsilon$

 $V \rightarrow bE \qquad E \rightarrow \varepsilon$

 $H_0(X) = H_1(X) = H(X) = \{X\} \quad (X \in \{V, Z_1, Z_2, E\})$

 $H_0(B) = \{B\}, H_1(B) = H_2(B) = H(B) = \{B, V\}.$

 $H_0(S) = \{S\}, H_1(S) = \{S, B\}, H_2(S) = H_3(S) = H(S) = \{S, B, V\}.$

Motiváció:

Vegyük észre, hogy minden véges nyelv reguláris. Tudjuk továbbá, hogy az \mathcal{L}_3 nyelvosztály (a reguláris nyelvek osztálya) zárt az unió, a konkatenáció és az iteratív lezárt műveletekre nézve.

Következésképpen, kiindulva véges számú véges nyelvből és az előzőekben felsorolt, ún. reguláris műveleteket véges sokszor alkalmazva reguláris nyelvet kapunk.

Kérdés az, hogy vajon ezzel az eljárással minden reguláris nyelvet elő tudunk-e állítani, azaz, ez a módszer elégséges-e az \mathcal{L}_3 nyelvosztály leírására?

Definíció

Legyenek V és $V' = \{\emptyset, \varepsilon, \cdot, +, *, (,)\}$ diszjunkt ábécék. A V ábécé feletti **reguláris kifejezéseket** rekurzív módon a következőképpen definiáljuk:

- 1. Ø reguláris kifejezés V felett,
- 2. ε reguláris kifejezés V felett,
- 3. a reguláris kifejezés V felett, ha $a \in V$,
- 4. Ha R reguláris kifejezés V felett, akkor R* is reguláris kifejezés V felett,
- 5. Ha Q és R reguláris kifejezések V felett, akkor $(Q \cdot R)$ is,
- 6. Ha Q és R reguláris kifejezések V felett, akkor (Q + R) is.

Minden egyes R reguláris kifejezés egy-egy L(R)-rel jelölt reguláris nyelvet határoz meg, amelyeket az alábbi rekurzióval definiálunk.

Definíció

- 1. $L(\emptyset) := \emptyset$,
- 2. $L(\varepsilon) := \{\varepsilon\},$
- 3. $L(a) := \{a\} (a \in V),$
- 4. $L(R^*) := L(R)^*$, ha R reguláris kifejezés,
- 5. $L(Q \cdot R) := L(Q)L(R)$, ha Q, R reguláris kifejezések,
- 6. $L(Q+R) := L(Q) \cup L(R)$, ha Q, R reguláris kifejezések.

Azaz a *, · és + szimbólumok jelölik rendre a lezárt, a konkatenáció és az unió műveleteket jelölik.

Megjegyzés: (Q + R) helyett használatosak még a $(Q \mid R)$ illetve a $(Q \cup R)$ jelölések is.

R-et és L(R)-et sokszor azonosítjuk.

Például írunk olyat, hogy $ab^* = \{ab^n \mid n \in \mathbb{N}\}.$

Legyen *P*, *Q* és *R* reguláris kifejezések. Ekkor fennállnak a következő azonosságok:

1.
$$P + (Q + R) = (P + Q) + R$$

2.
$$P \cdot (Q \cdot R) = (P \cdot Q) \cdot R$$

3.
$$P + Q = Q + P$$

$$4. P \cdot (Q + R) = P \cdot Q + P \cdot R$$

5.
$$(P+Q) \cdot R = P \cdot R + Q \cdot R$$

6.
$$P^* = \varepsilon + P \cdot P^*$$

7.
$$\varepsilon \cdot P = P \cdot \varepsilon = P$$

8.
$$P^* = (\varepsilon + P)^*$$

9.
$$P \cdot \emptyset = \emptyset \cdot P = \emptyset$$

A műveletek precedenciasorrendje *,·,+, ennek és az asszociatív szabályok figyelembevételével bizonyos zárójelpárok elhagyhatók.

Példa:

Az $(a + b)a^*$ és $aa^* + ba^*$ reguláris kifejezések által leírt nyelv ugyanaz: $\{aa^n \mid n \in \mathbb{N}\} \cup \{ba^n \mid n \in \mathbb{N}\}.$

Viszont $(a + b)a^* \neq a + ba^*$, hiszen az utóbbi által leírt nyelv $\{a, b, ba, ba^2, ba^3, \ldots\}$.

Reguláris kifejezések – Arden tétele

Az alábbi tételt később, a reguláris kifejezések véges automatákkal való kapcsolatának vizsgálatakor fogjuk használni:

Arden tétele

Adottak az R és Q reguláris kifejezések. A $P = R + P \cdot Q$ egyenletnek P-re vonatkozó megoldása $P = R \cdot Q^*$. Amennyiben $\varepsilon \notin Q$, akkor az egyenletnek ez az egyetlen megoldása.

Példa: A $P = ab^* + Pbc^*$ egyenlet egyértelmű megoldása $P = ab^*(bc^*)^*$.

Bizonyítás:

(1) $P = R \cdot Q^*$ megoldás:

$$R + P \cdot Q = R + (R \cdot Q^*) \cdot Q = R + R \cdot (Q \cdot Q^*) = R \cdot (\varepsilon + Q \cdot Q^*) = R \cdot Q^* = P.$$

Reguláris kifejezések – Arden tétele

(2) A megoldás egyértelműsége:

$$P = R + P \cdot Q = R + (R + P \cdot Q) \cdot Q = R + RQ + PQ^2 = \cdots = R + RQ + \cdots + RQ^n + PQ^{n+1}$$
, ahol *n* tetszőleges nagy lehet, azaz

$$P = R(\varepsilon + Q + \cdots Q^n) + PQ^{n+1}.$$
 (*)

Legyen $w \in P$ és n = |w| az előző (*) képletben. Mivel $\varepsilon \notin Q$ ezért $w \notin PQ^{n+1}$ (minden szava legalább n+1 hosszú), tehát $w \in R(\varepsilon + Q + \ldots + Q^n) \subseteq RQ^*$.

Fordítva, ha $w \in RQ^*$, akkor $\exists n \in \mathbb{N}$, hogy $w \in RQ^n$, azaz benne van (*) jobboldalában, azaz P-ben is.

Tehát csak $P = R \cdot Q^*$ lehetséges.

Tétel

Minden reguláris kifejezés egy reguláris (3-típusú) nyelvet jelöl, és megfordítva, minden reguláris nyelvhez megadható egy, ezen nyelvet jelölő reguláris kifejezés.

Bizonyítás:

- **1.** Az, hogy reguláris kifejezések csak reguláris nyelvet jelölhetnek következik az \emptyset , $\{\varepsilon\}$, $\{a\}$ $(a \in V)$ nyelvek reguláris voltából és \mathcal{L}_3 reguláris műveletekre való zártságából.
- **2.** Megmutatjuk, hogy minden L reguláris nyelvhez, amelyet a $G = \langle N, T, P, S \rangle$ normálformában adott reguláris grammatika generál, meg tudunk konstruálni egy reguláris kifejezést, amely az L nyelvet jelöli.

Legyen $N = \{A_1, ..., A_n\}, n \ge 1, S = A_1$. (*G* minden szabálya vagy $A_i \to aA_j$ vagy $A_i \to \varepsilon$ alakú, ahol $a \in T, 1 \le i, j \le n$.)

Azt mondjuk, hogy az $A_i \Rightarrow^* uA_j \ (u \in T^*)$ levezetés **érinti** az A_m nemterminálist, ha A_m előfordul valamely közbülső mondatformában az $A_i \Rightarrow^* uA_i$ levezetésben.

Az $A_i \Rightarrow^* uA_j$ levezetést ℓ -megszorítottnak nevezzük, ha $1 \le m \le \ell$ teljesül minden A_m nemterminálisra, amelyet a levezetés érint.

Definiáljuk a következő halmazokat $0 \le k \le n, 1 \le i, j \le n$ -re:

$$E_{i,j}^k = \{u \in T^* \mid \text{létezik } A_i \Rightarrow^* uA_j \text{ k-megszorított levezetés} \}.$$

Az $i \neq j$ esetben az $E_{i,j}^0$ halmaz vagy üres vagy T-beli betűkből áll: $a \in E_{i,j}^0$, akkor és csak akkor, ha $A_i \to aA_j \in P$.

Ha i = j, akkor $E_{i,i}^0$ tartalmazza ε -t és nulla vagy több elemét T-nek (ha $A_i \to aA_i \in P$).

k-ra vonatkozó indukcióval bizonyítunk. Látható, hogy $E_{i,j}^0$ reguláris kifejezéssel jelölhető.

Tegyük fel, hogy rögzített k-ra (0 < $k \le n$), az $E_{i,j}^{k-1}$ nyelvek mindegyike jelölhető reguláris kifejezéssel.

Nyilvánvaló, hogy

$$E_{i,j}^k = E_{i,j}^{k-1} + E_{i,k}^{k-1} \cdot (E_{k,k}^{k-1})^* \cdot E_{k,j}^{k-1}$$

ezért az indukciós hipotézis alapján $E_{i,j}^k$ szintén jelölhető reguláris kifejezéssel.

Legyen I_{ε} azon i indexek halmaza, amelyekre $A_i \to \varepsilon \in P$. Akkor $L(G) = \bigcup_{i \in I_{\varepsilon}} E_{1,i}^n$, azaz L reguláris kifejezéssel jelölhető.

1. Példa:

 $R = a(a + ba^*)^*$. Készítsünk 3-típusú grammatikát R-hez!

A zártsági tétel konstrukcióit alkalmazzuk.

Legyen
$$R_1 = a$$
, $R_2 = ba^*$, $R_3 = R_1 + R_2$, $R_4 = R_3^*$.

$$R_1: A \rightarrow a$$

$$R_2: B \to bC, C \to aC \mid \varepsilon$$
 (kezdőszimbólum: B)

$$R_3: D \rightarrow A \mid B, A \rightarrow a, B \rightarrow bC, C \rightarrow aC \mid \varepsilon$$
 (kezdőszimbólum: D)

$$R_4: X \to D \mid \varepsilon, D \to A \mid B, A \to a \mid aD, B \to bC, C \to aC \mid \varepsilon \mid D$$
 (kezdőszimbólum: X)

$$R: S \to aX, X \to D \mid \varepsilon, D \to A \mid B, A \to a \mid aD, B \to bC,$$

 $C \to aC \mid \varepsilon \mid D$ (kezdőszimbólum: S)

2. Példa: [a példában az $R^+ := RR^*$ rövidítést használjuk]

$$A_1 \rightarrow bA_1 \mid aA_2$$

$$A_2 \rightarrow bA_1 \mid \varepsilon$$

Például:

$$E_{12}^2 = E_{12}^1 + E_{12}^1 (E_{22}^1)^* E_{22}^1 =$$
 $b^* a + b^* a (\varepsilon + b^+ a)^* (\varepsilon + b^+ a) = b^* a + b^* a (b^+ a)^* = b^* a (b^+ a)^*.$
 $L(G) = E_{12}^2 = b^* a (b^+ a)^*.$